Tecnológico de Monterrey

Actividad 8

Regresión no lineal

Análitica de datos y herramientas de inteligencia artificial

02 de noviembre de 2026

Rodrigo Zapien Barrios | A01424400

El objetivo de esta actividad es analizar la correlación no lineal entre variables numéricas de la base del socio formador CLV, aplicando dos modelos de regresión no lineal: exponencial y potencial. La recta lineal se conserva únicamente como punto de comparación.

1. Bases de datos incorporadas

Se trabajó con dos bases: la hoja “Negocios_CRM”, ya analizada en la actividad de regresión lineal, y el histórico de ventas “Ventas_CLV_2022_2026”, incorporado en esta actividad. Reutilizar Negocios permite comparar directamente los resultados lineales y no lineales sobre los mismos datos.

Base	Archivo / hoja	Registros originales	Unidad de análisis	Registros finales
Negocios (CRM)	Datos_CLV_2026_Tec_v2.xlsx, hoja Negocios	5,268 filas, 20 columnas	Negocio ganado	642 negocios
Ventas	Ventas_CLV_2022_2026.csv	114,501 partidas, 15 columnas	Cliente (partidas agrupadas)	4,742 clients

Variables analizadas:

- **Negocios:** valor_negocio (monto real del negocio, en pesos), numero_actividades (actividades registradas) y dias_cierre (días entre fecha de creación y fecha de cierre, variable derivada).
- **Clientes (Ventas):** total_comprado (suma de total_neto por cliente, en pesos), n_folios (facturas distintas), n_marcas (marcas distintas compradas) y unidades (suma de total_unidades).

2. Preprocesamiento

Ambas bases presentan sesgo extremo y ceros que impiden aplicar logaritmos; por eso, además de tratar nulos y atípicos, se aplicaron transformaciones específicas para los modelos no lineales.

2.1 Base Negocios

Transformaciones de tipo. valor_previsto y valor_negocio venían como texto (con $ y comas) y se convirtieron a numérico; las fechas se convirtieron a datetime.

Nulos. Tras la conversión aparecieron 23 nulos en valor_negocio y numero_actividades (filas con columnas desfasadas: texto en lugar de montos), 30 en fecha_creacion y 109 en fecha_cierre.

Filtrado. El análisis se limita a negocios ganados con monto real:

1. Negocios en etapa Cierre Ganado o Ganado: 4,099
2. Con valor_negocio > 0: 669 (los negocios perdidos o abiertos tienen valor 0)
3. Se creó dias_cierre y se eliminaron 3 nulos y 24 días negativos (errores de captura): 642 negocios finales

Ceros. 337 negocios tienen dias_cierre = 0 y 362 tienen numero_actividades = 0. Como el modelo potencial (x^b) y el logaritmo no admiten ceros, se crearon dias_cierre_1 = dias_cierre + 1 y actividades_1 = numero_actividades + 1.

Atípicos (IQR). Se identificaron, pero no se eliminaron de la base: se usaron en el análisis de sensibilidad (sección 4).

Variable	Atípicos	Límites IQR	Sesgo
valor_negocio	91	-13,435.36 a 26,516.40	21.21
numero_actividades	54	-1.5 a 2.5	2.86
dias_cierre	99	-7.12 a 11.88	3.01

2.2 Base Ventas (tabla por cliente)

Nulos. Solo cp tiene nulos (5,188); no es una variable del análisis, por lo que no se imputó.

Duplicados. Se eliminaron 1,754 filas duplicadas exactas.

Partidas sin costo. 4,703 partidas tienen total_neto = 0 y no representan una compra real; se excluyeron, quedando 108,044 partidas.

Transformación (agregación). Las partidas se agruparon por nombre_cliente, obteniendo 4,742 clientes. n_folios, n_marcas y unidades valen al menos 1, por lo que no requirieron el ajuste +1.

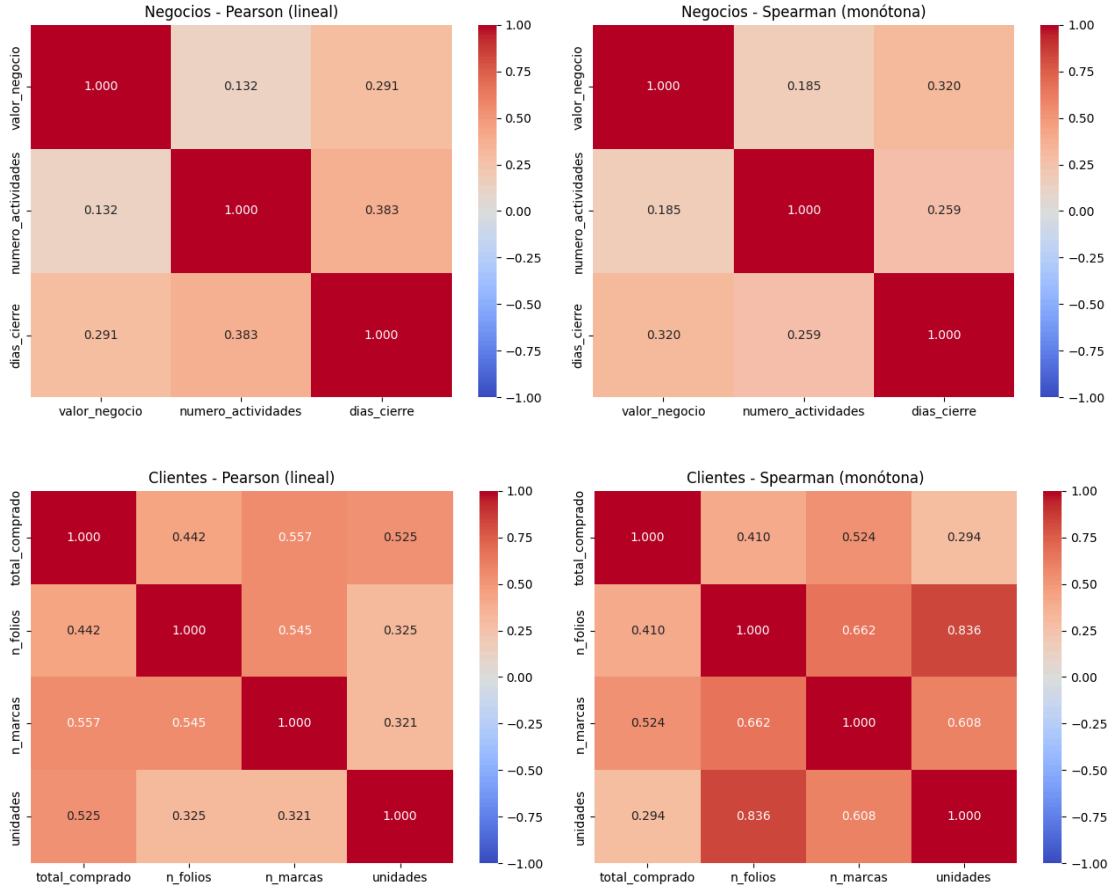
Variable	Atípicos	Límites IQR	Sesgo
total_comprado	466	-120,717.47 a 207,579.44	28.61
n_folios	686	-3.5 a 8.5	25.98
n_marcas	552	-0.5 a 3.5	3.71
unidades	693	-19.0 a 37.0	39.42

2.3 Evidencia de no linealidad

Antes de modelar se compararon Pearson (relación lineal) y Spearman (relación monótona). Cuando difieren, la relación no es una recta o está dominada por valores extremos.

Base	Par	Pearson	Spearman	Lectura
Negocios	valor_negocio – dias_cierre	0.291	0.320	Monótona, no recta
Negocios	valor_negocio – numero_actividades	0.132	0.185	Monótona, no recta
Negocios	numero_actividades – dias_cierre	0.383	0.259	Cercana a lineal
Clientes	total_comprado – n_marcas	0.557	0.524	Similar

Base	Par	Pearson	Spearman	Lectura
Clientes	total_comprado – n_folios	0.442	0.410	Similar
Clientes	total_comprado – unidades	0.525	0.294	Pearson inflado por extremos



3. Modelos de regresión no lineal

Se eligieron los modelos exponencial y potencial porque las variables tienen sesgo positivo extremo y crecen de forma más que proporcional en sus valores altos; ambos se pueden linealizar con logaritmos.

3.1 Modelos y método

Modelo exponencial: Y crece a una tasa porcentual constante por cada unidad adicional de X.

Modelo potencial: Y cambia en un porcentaje constante por cada cambio porcentual de X; b es una elasticidad.

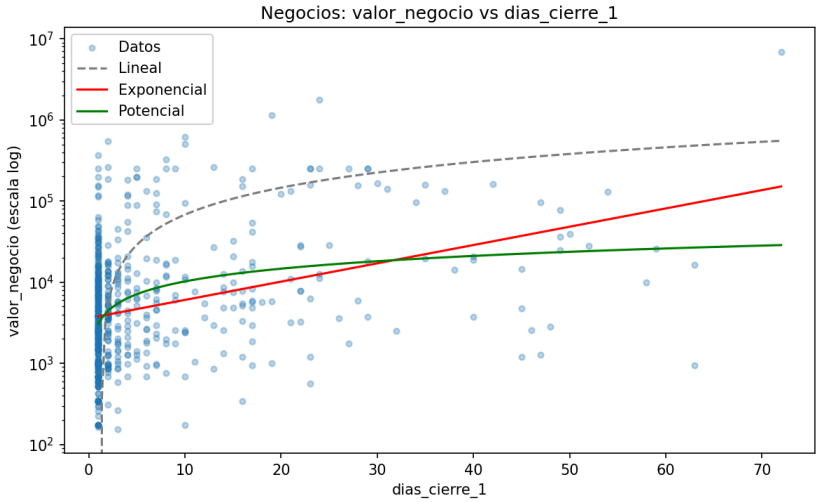
Método. Ambos modelos se ajustaron por linealización: se aplicó logaritmo natural y se estimó una recta por mínimos cuadrados con `np.polyfit`. Se eligió este método porque, con sesgos de 21 a 39, un ajuste directo en pesos quedaría determinado por unos cuantos clientes extremos (por ejemplo, uno de 24.1 millones).

Medidas reportadas. Para cada modelo se obtuvo r (correlación de la recta linealizada) y $R^2 = r^2$. En los modelos no lineales, R^2 se mide en escala logarítmica; por ello se agregó el R^2 en escala original (pesos o unidades reales) como dato complementario. El modelo lineal (y = a + b·x) se incluye como referencia.

3.2 Negocios: valor_negocio vs dias_cierre

Modelo	Ecuación	r	R^2
Lineal	y = -10,266.05 + 7,830.72·x	0.2911	0.0847
Exponencial	y = 3,599.69·e^(0.0519·x)	0.3366	0.1133
Potencial	y = 3,071.31·x^0.5224	**0.3750**	**0.1406**

x = dias_cierre + 1.

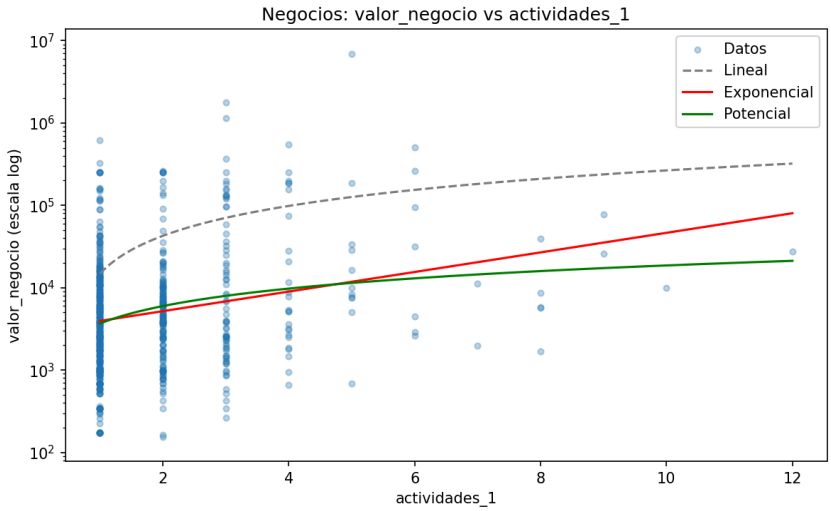


El modelo potencial es el mejor. Los negocios que tardan más en cerrarse tienen mayor valor, pero el crecimiento se desacelera (b = 0.52 < 1). Con el exponencial, cada día adicional se asocia con alrededor de 5.3% más de valor (e^0.0519 − 1). Este modelo exponencial reproduce exactamente el modelo log_valor ~ dias_cierre de la actividad de regresión lineal (r = 0.3366): aquel modelo ya era un exponencial linealizado.

3.3 Negocios: valor_negocio vs numero_actividades

Modelo	Ecuación	r	R^2
Lineal	y = -13,053.36 + 27,846.74·x	0.1321	0.0174
Exponencial	y = 3,001.46·e^(0.2737·x)	0.2264	0.0512
Potencial	y = 3,667.37·x^0.7057	**0.2323**	**0.0539**

x = numero_actividades + 1.

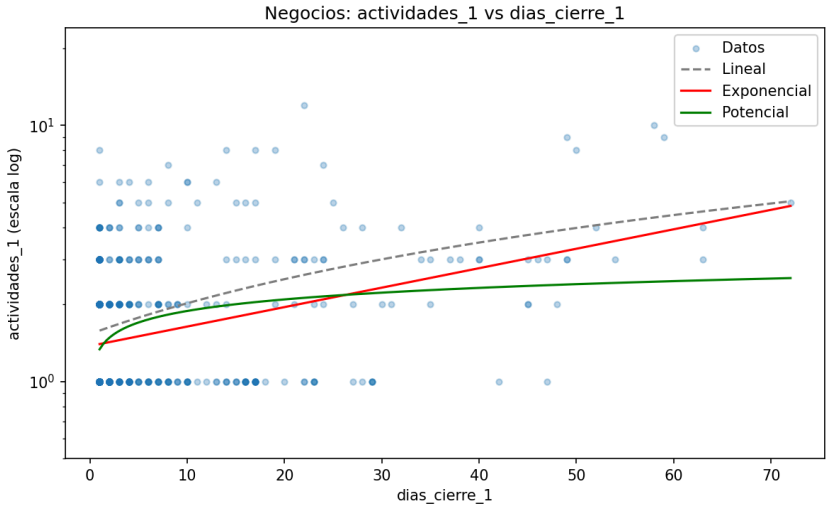


Los modelos no lineales casi duplican la correlación de la recta (0.13 a 0.23), aunque la relación sigue siendo débil. Cada actividad adicional se asocia con alrededor de 31% más de valor (e^0.2737 − 1). El número de actividades por sí solo explica poco del monto de un negocio.

3.4 Negocios: numero_actividades vs dias_cierre

Modelo	Ecuación	r	R^2
Lineal	y = 1.5321 + 0.0489·x	**0.3830**	**0.1467**
Exponencial	y = 1.3763·e^(0.0175·x)	0.3442	0.1184
Potencial	y = 1.3365·x^0.1495	0.3261	0.1063

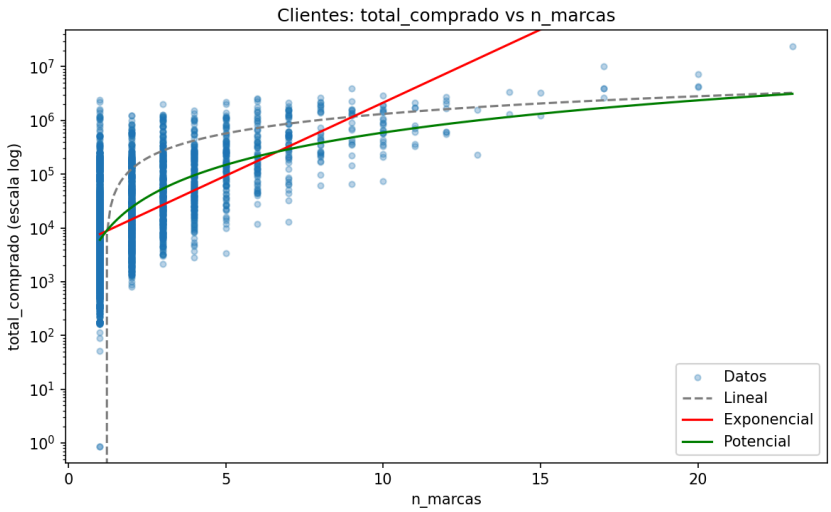
x = dias_cierre + 1; y = numero_actividades + 1.



Es el único par donde la recta gana, con todos los datos y sin atípicos. Las actividades aumentan de forma casi proporcional al tiempo que el negocio permanece abierto. No toda relación de la base es no lineal.

3.5 Clientes: total_comprado vs n_marcas

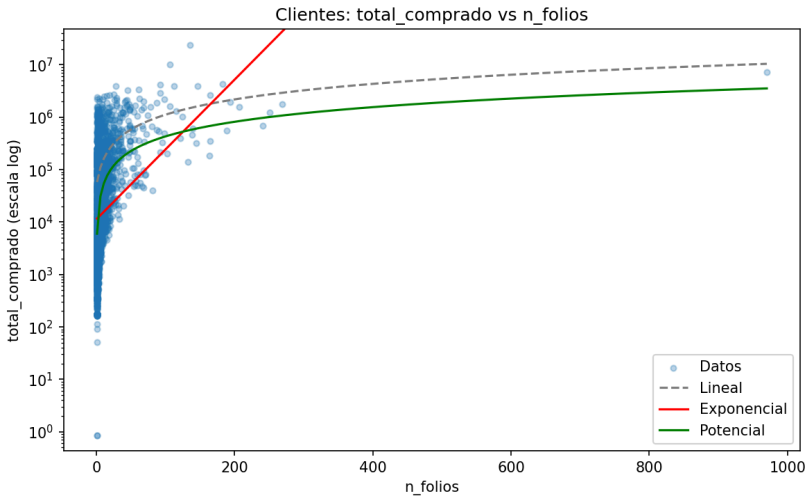
Modelo	Ecuación	r	R^2
Lineal	y = -175,168.17 + 149,638.14·x	0.5566	0.3098
Exponencial	y = 4,107.03·e^(0.6259·x)	0.5301	0.2810
Potencial	y = 6,022.72·x^1.9941	**0.5627**	**0.3166**



Es la relación más fuerte del análisis. Con b ≈ 2, duplicar las marcas que compra un cliente multiplica su compra total por cerca de 4 (2^1.99 ≈ 3.97). La recta, además, predice compras negativas para clientes de una sola marca (intercepto de -175,168), lo cual no tiene sentido.

3.6 Clientes: total_comprado vs n_folios

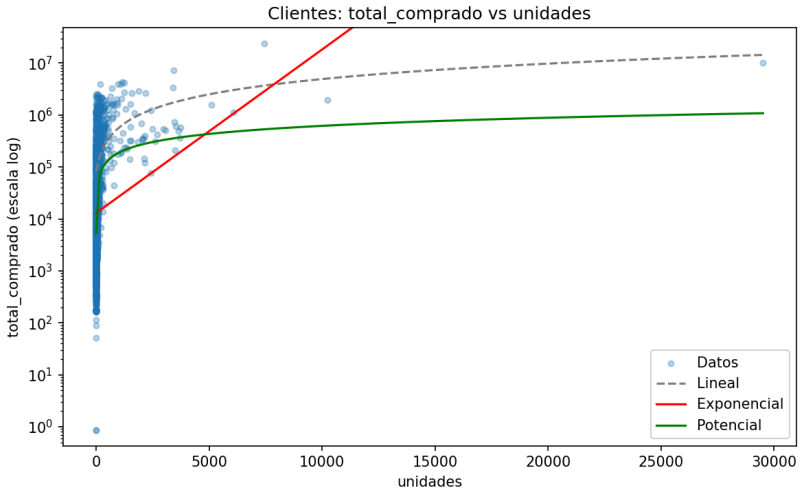
Modelo	Ecuación	r	R^2
Lineal	y = 47,134.92 + 10,706.60·x	0.4416	0.1950
Exponencial	y = 11,313.55·e^(0.0307·x)	0.2880	0.0829
Potencial	y = 6,010.09·x^0.9276	**0.4689**	**0.2198**



Con b = 0.93 la relación es casi proporcional: el doble de facturas equivale a poco menos del doble de compra. El exponencial falla porque e^(bx) se dispara con clientes de hasta 970 folios.

3.7 Clientes: total_comprado vs unidades

Modelo	Ecuación	r	R^2
Lineal	y = 82,824.15 + 484.87·x	**0.5246**	**0.2752**
Exponencial	y = 13,015.46·e^(0.0007·x)	0.1786	0.0319
Potencial	y = 5,304.09·x^0.5169	0.3981	0.1585



La recta gana solo en apariencia: su correlación depende de unos pocos clientes extremos (Spearman de apenas 0.294 y caída a 0.155 sin atípicos; ver sección 4). El potencial (b = 0.52) muestra rendimientos decrecientes: los clientes que compran muchas unidades tienden a comprar artículos de menor precio.

4. Tabla de coeficientes de determinación y correlación

El modelo potencial obtiene la mayor correlación en 4 de los 6 pares con todos los datos y en los 3 pares de Clientes sin atípicos; el exponencial solo es competitivo en la base Negocios, donde las X son pequeñas.

4.1 Tabla general (todos los datos)

Base	Y vs X	n	r lineal	R^2 lineal	r exponencial	R^2 exponencial	r potencial	R^2 potencial	Mejor modelo
Negocios	valor_negocio vs dias_cierre	642	0.2911	0.0847	0.3366	0.1133	**0.3750**	**0.1406**	Potencial
Negocios	valor_negocio vs numero_actividades	642	0.1321	0.0174	0.2264	0.0512	**0.2323**	**0.0539**	Potencial
Negocios	numero_actividades vs dias_cierre	642	**0.3830**	**0.1467**	0.3442	0.1184	0.3261	0.1063	Lineal
Clientes	total_comprado vs n_marcas	4,742	0.5566	0.3098	0.5301	0.2810	**0.5627**	**0.3166**	Potencial
Clientes	total_comprado vs n_folios	4,742	0.4416	0.1950	0.2880	0.0829	**0.4689**	**0.2198**	Potencial
Clientes	total_comprado vs unidades	4,742	**0.5246**	**0.2752**	0.1786	0.0319	0.3981	0.1585	Lineal (inflado por extremos)

4.2 Sensibilidad sin atípicos

Se repitieron los ajustes eliminando los atípicos altos de Y (criterio IQR). La recta pierde gran parte de su correlación porque dependía de unos cuantos valores extremos; los modelos no lineales conservan mucho más.

Base	Y vs X	n	r lineal	r exponencial	r potencial	Mejor modelo
Negocios	valor_negocio vs dias_cierre	551	**0.2197**	0.1804	0.2138	Lineal (empate con potencial)
Negocios	valor_negocio vs numero_actividades	551	0.0801	**0.1145**	0.1096	Exponencial
Negocios	numero_actividades vs dias_cierre	588	**0.2545**	0.2282	0.1810	Lineal
Clientes	total_comprado vs n_marcas	4,276	0.2865	0.3872	**0.4108**	Potencial
Clientes	total_comprado vs n_folios	4,276	0.1829	0.2648	**0.3351**	Potencial
Clientes	total_comprado vs unidades	4,276	0.1552	0.1548	**0.2329**	Potencial

En Clientes, la recta pasa de 0.525 a 0.155 en unidades y de 0.557 a 0.287 en n_marcas, mientras que el potencial conserva entre 58% y 73% de su correlación. El modelo potencial describe mejor al cliente típico; la recta describe sobre todo a los clientes más grandes.

4.3 R^2 en escala original

Como complemento, se calculó el R^2 de los modelos no lineales en pesos o unidades reales.

Base	Y vs X	R^2 exponencial (original)	R^2 potencial (original)
Negocios	valor_negocio vs dias_cierre	0.0258	-0.0037
Negocios	valor_negocio vs numero_actividades	-0.0104	-0.0102
Negocios	numero_actividades vs dias_cierre	0.1011	0.0733
Clientes	total_comprado vs n_marcas	-50,121.56	**0.2943**
Clientes	total_comprado vs n_folios	-7.75 × 10^18	0.0939
Clientes	total_comprado vs unidades	-5.69 × 10^11	0.0470

Un R^2 negativo indica que el modelo predice peor que el promedio de Y. Los valores extremos del exponencial en Clientes muestran que la curva e^(bx) se dispara con X grandes, por lo que este modelo no es adecuado para esa base. El potencial mantiene un R^2 positivo en los tres pares de Clientes, con 0.29 en n_marcas.

Conclusiones

El modelo potencial es el más adecuado para la base CLV: gana en 4 de 6 pares con todos los datos, en los 3 pares de Clientes sin atípicos, y es el único no lineal con R^2 positivo en escala original en Clientes.

La superioridad del modelo potencial sobre el exponencial se explica por la forma en que cada uno trata el sesgo. Al aplicar logaritmo en ambos ejes, el potencial absorbe la asimetría tanto de X como de Y, mientras que el exponencial solo transforma Y. Por ello, el exponencial funciona razonablemente en Negocios, donde las X son pequeñas (máximo 72 días y 12 actividades), pero se dispara en Clientes, donde hay clientes con hasta 970 folios o 29,511 unidades.

El análisis de sensibilidad mostró además que la correlación lineal estaba inflada. En Clientes, la recta pierde hasta 70% de su correlación al eliminar los atípicos, mientras que el potencial conserva entre 58% y 73%. Esto indica que los resultados lineales describen principalmente a los clientes más grandes, y que el modelo potencial representa mejor el comportamiento del cliente típico.

Estos resultados tienen continuidad con la actividad de regresión lineal. El modelo exponencial de valor_negocio reproduce exactamente las correlaciones del modelo log_valor de esa actividad (0.3366 con dias_cierre y 0.2264 con numero_actividades), lo que confirma que aquel modelo ya era un exponencial linealizado. Esta actividad lo formaliza y muestra que el modelo potencial lo mejora, alcanzando 0.3750 con dias_cierre.

No todas las relaciones resultaron no lineales. El par numero_actividades vs dias_cierre se ajusta mejor con la recta ($r = 0.383$), tanto con todos los datos como sin atípicos: las actividades crecen de forma casi proporcional al tiempo que un negocio permanece abierto.

Para el socio formador, el hallazgo más relevante es que la diversificación de marcas es el principal motor de compra. Con un exponente cercano a 2, duplicar las marcas que adquiere un cliente se asocia con casi cuatro veces su compra total, por lo que las estrategias de venta cruzada entre marcas tienen un efecto más que proporcional sobre los ingresos.

Finalmente, el análisis tiene limitaciones. Las correlaciones de Negocios son débiles ($R^2 \leq 0.15$), lo que sugiere que el valor de un negocio depende de factores no incluidos en estos modelos. Además, los R^2 de los modelos linealizados se miden en escala logarítmica y no son idénticos al R^2 en pesos, razón por la cual se reportaron ambos. La base Relación de tiempos de entrega se omitió por su baja completitud.